UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario



Laboratorio No. 11

Data Science

Sección: 10

Jose Ordoñez - 231329

Gadiel Ocaña - 231270

Adrián Gonzáles - 23152

José Antón - 221041

Guatemala, 2026

Defina el alcance del flujo

Variable, unidad y nivel de agregación

Tabla 1. Variable, unidad y agregación

Elemento	Definición
Variable estimada	Llegadas internacionales de viajeros a Guatemala por mes.
Unidad de medida	Viajeros por mes (personas/mes). No son personas únicas, pernoctaciones, gasto turístico ni visitantes por departamento.
Nivel de agregación	Mensual. Total nacional y seis segmentos: Total, Vía Aérea, Vía Terrestre, Vía Marítima, América del Centro, América del Norte y Europa.
Cobertura observada	Enero 2009 – junio 2026 (210 meses). 2026 solo contiene enero–junio.
Universo	Registros de INGUAT/Migración procesados en los Laboratorios 1 y 2. Las vistas por país o frontera son descriptivas y no se publican como estimaciones modeladas.

Fuentes y columnas

Tabla 2. Fuentes y columnas utilizadas

Elemento	Definición
Fuente primaria	Base_Migracion_2009-2026jun.xlsx (INGUAT/Migración), corte a junio 2026. El archivo no se incorpora a la imagen Docker; se monta como dato institucional.
Columnas utilizadas	Año, Mes cod, Vía, Frontera, País, Región dos, Tipo de Viajero y Viajero.
Archivos derivados	data/base_viajeros.csv.gz (detalle), data/series_mensuales.csv (serie observada), data/predicciones_lab1.csv y data/metricas_lab1.csv (resultados del Laboratorio 1).
Construcción de la serie	Suma de Viajero por Año y Mes cod. No se construye a partir de presencias diarias ni de una fuente distinta a la mensual.
Filtro metodológico	Se excluye Tipo de Viajero == "Viajero" en todas las series, excepto en Vía Marítima, que se usa completa. Esto responde al cambio de metodología 2022–2023 y evita duplicar visitantes.
Faltantes y fechas	Un mes sin fila en la fuente es un faltante, no un cero. Un cero solo es válido si la fuente lo reporta. Las fechas inválidas o los períodos esperados sin cobertura detienen el flujo.

Factor de reparto

El factor de reparto se documenta como el conjunto de proporciones con que la fuente distribuye el total de viajeros entre Turista, Excursionista, Viajero y Cruceristas. En la base recibida ese reparto ya está aplicado: por eso la columna Viajero contiene decimales y la suma por grupo recupera el total. El pipeline no vuelve a aplicar el factor, conserva los decimales hasta la

agregación y redondea solo para presentación. Si el equipo dispone de la tabla explícita de factores, se guarda en config/factores_reparto.csv y se versiona. Para la asignación a destinos se usa el factor oficial de la guía; en esta versión nacional cada llegada se cuenta una vez, por lo que el factor de asignación es 1.0.

Períodos de ajuste, evaluación y publicación

Tabla 3. Períodos del flujo

Etapa	Período	Uso
Ajuste base	2009-01 a 2021-03 (147 meses)	Entrenamiento con el mismo corte del Laboratorio 1.
Evaluación histórica	2021-04 a 2026-06 (63 meses)	Comparación con los resultados del Laboratorio 1. No es la única base de aceptación porque es un pronóstico multimensual y contiene la recuperación pospandemia.
Backtest de aceptación	2025-07 a 2026-06 (12 cortes)	Evaluación principal con origen expansivo y un paso hacia adelante: en cada corte se ajusta solo con información anterior al mes evaluado.
Pronóstico publicado	2026-07 a 2026-12 (6 meses)	Estimaciones hacia adelante con el corte de junio 2026.
Sensibilidad ene–feb 2026	Enero y febrero 2026	Se pueden ocultar y estimar, pero se documenta la limitación: el corte actual ya contiene esos valores y el código se especificó después de verlos; además, la pandemia y el cambio metodológico impiden un contrafactual limpio. Si no hay observaciones comparables, no se calculan errores.

Parámetros y supuestos

Tabla 4. Parámetros y supuestos del procedimiento

Parámetro o supuesto	Valor o criterio
ARIMA por serie	Total (1,0,1); Aérea (1,0,1); Terrestre (2,1,0); Marítima (2,0,3); Centro (1,0,0); Norte (3,0,0); Europa (4,1,2).
Seasonal Naive	Repite el mismo mes del año anterior. Se usa como referencia sencilla.
Prophet	Estacionalidad anual activa; semanal y diaria desactivadas.
Transformación logarítmica	Se aplica solo si la diferencia entre el CV anual máximo y mínimo es mayor que 0.25 y todos los valores son positivos. La regla queda en configuración y se registra por serie.

Semilla y dependencias	Semilla 20261029 para cualquier componente aleatorio. Versiones fijadas en requirements.txt o en el archivo de bloqueo y registradas en MLflow.
Selección de modelo	Los parámetros se fijan con el Laboratorio 1 y no se reajustan con el período de prueba. La regla de aceptación se define antes de ver los resultados y no se modifica después.
Aditividad	Las filas de la fuente son aditivas dentro de mes, vía, frontera, país, región y tipo de viajero. Si hay duplicados, se documenta si son registros parciales aditivos o un error; no se eliminan silenciosamente.
Continuidad	Las estimaciones suponen que el patrón histórico y la estacionalidad se mantienen. No anticipan pandemias, cambios metodológicos ni shocks externos.
Revisiones de la fuente	Si INGUAT revisa datos históricos, la versión publicada puede cambiar; por eso se registra el hash de la fuente y la fecha de generación.
MAPE y redondeo	El MAPE se calcula solo cuando las observaciones son mayores que cero. Si hay ceros, se reporta cuántas observaciones se excluyeron y se usan MAE/RMSE como métricas principales. Los valores se conservan con decimales en el archivo; el tablero redondea solo para mostrar.

Archivo de resultados que utilizará el tablero

La publicación se organiza en versiones inmutables y un puntero atómico. El tablero lee únicamente current.json y el archivo de la versión aprobada; nunca lee un archivo candidato. Si el puntero no existe o está corrupto, muestra “estimaciones no disponibles”.

Tabla 5. Esquema mínimo de estimaciones.csv

Columna	Descripción
destino	Guatemala (o el destino asignado, si aplica).
serie	Total, Vía Aérea, Vía Terrestre, Vía Marítima, América del Centro, América del Norte o Europa.
periodo	Mes estimado, formato YYYY-MM-01.
valor	Viajeros por mes.
unidad	viajeros/mes.
modelo	Modelo que generó la estimación.
conjunto	evaluacion o pronostico.
horizonte	Meses hacia adelante; 0 en backtest.
run_id	Identificador de la ejecución en MLflow.
fecha_generacion	Fecha y hora ISO 8601.
version_procedimiento	Versión publicada, por ejemplo v2026.10.29-01.

fuente_hash / config_hash	SHA-256 de la fuente y de la configuración.
estado	aprobado o referencia. El tablero usa aprobado por defecto.

metricas.csv incluye serie, modelo, periodo_inicio, periodo_fin, n_obs, MAE, RMSE, MAPE_pct, baseline, baseline_MAE, baseline_RMSE, cumple_regla y run_id. controles.csv incluye control, severidad, estado, n_afectados, detalle, run_id y timestamp. manifest.json conserva la versión, el run_id, el commit de Git, los hashes, los períodos, la fecha de aprobación y el resumen de métricas.

Diagrama del flujo y puntos de control

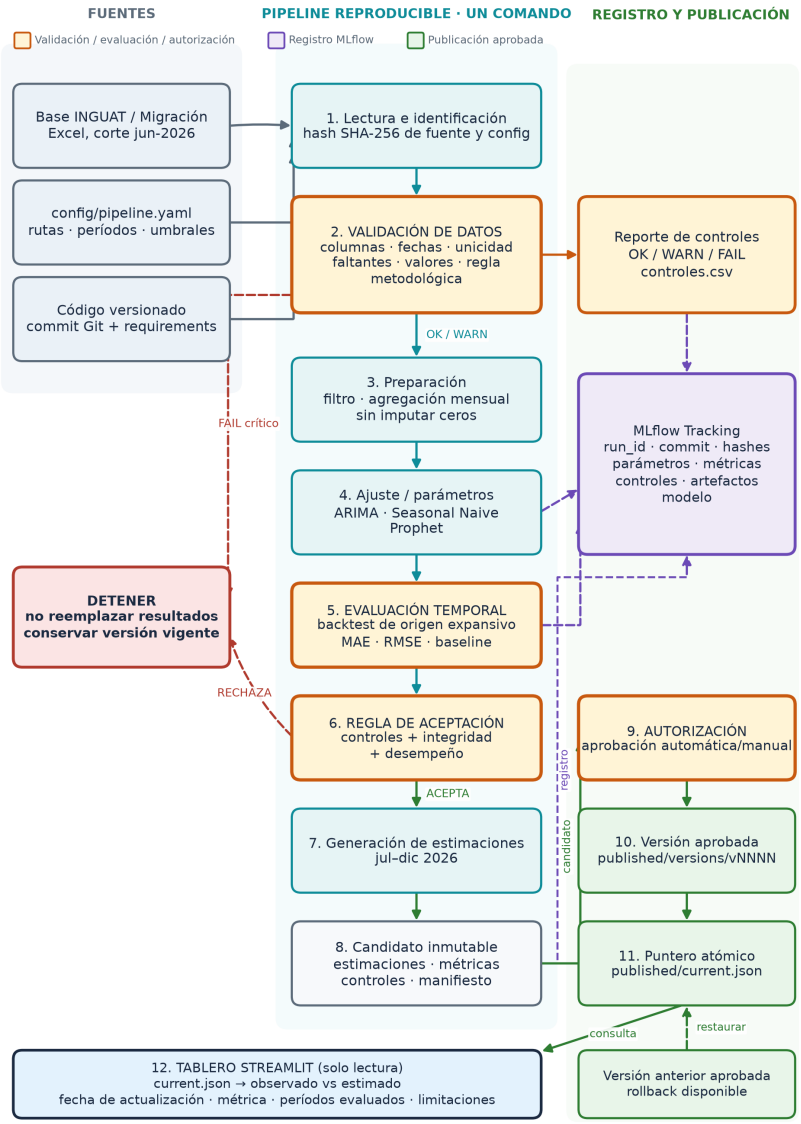


Figura 1. Flujo MLOps del Observatorio de Turismo Sostenible. Elaboración propia.

La validación ocurre antes de preparar las series: si falla un control crítico, el pipeline se detiene y no reemplaza los resultados vigentes. La evaluación se realiza después del ajuste y antes de generar la publicación; usa un backtest de origen expansivo para que cada estimación se calcule solo con información anterior al mes evaluado. La autorización ocurre después de registrar el candidato en MLflow; solo si se cumplen los controles y la regla de aceptación se actualiza el puntero de la versión aprobada.

Tabla 6. Puntos de validación, evaluación y autorización

Punto de control	Etapa	Qué se decide	Evidencia
Validación de datos	Etapa 2	Si los datos son aptos. Un FAIL crítico detiene el pipeline antes de preparar o reemplazar resultados.	Reporte de controles y artefacto en MLflow.
Evaluación del procedimiento	Etapa 5	Si el modelo es aceptable. Se usan solo datos anteriores a cada corte; no hay fuga de información futura.	MAE, RMSE, MAPE y comparación con la referencia.
Autorización de publicación	Etapa 9	Si el candidato reemplaza la versión vigente. Requiere controles críticos en OK, salidas válidas y cumplimiento de la regla de aceptación.	Run de MLflow y registro de aprobación.
Publicación	Etapas 10–11	Se guarda una versión inmutable y se actualiza el puntero de forma atómica. Si falla, se conserva la versión anterior.	current.json y manifest.json.
Consulta	Etapa 12	El tablero lee únicamente la versión aprobada y muestra fecha de actualización, métrica de validación, períodos evaluados y limitaciones.	Captura del tablero y versión consultada.

La regla de aceptación queda parametrizada en config/pipeline.yaml. Su estructura es: (i) todos los controles críticos en OK; (ii) todas las estimaciones finitas, no negativas y dentro de un rango plausible; (iii) MAE/RMSE del candidato por debajo de umbrales absolutos según la escala de la serie y no peor que la referencia en más de un margen justificado; (iv) si no hay observaciones comparables, no se calculan errores ni se aprueba por desempeño. Los valores numéricos exactos se fijan en la sección 5 y se congelan antes de ejecutar.