# UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario




## Laboratorio No. 11

Data Science

Sección: 10

Jose Ordoñez - 231329

Gadiel Ocaña - 231270

Adrián Gonzáles - 23152

José Antón - 221041

Guatemala, 2026

# Defina el alcance del flujo

## Variable, unidad y nivel de agregación

**Tabla 1. Variable, unidad y agregación**

| Elemento | Definición |
|---|---|
| **Variable estimada** | Llegadas internacionales de viajeros a Guatemala por mes. |
| **Unidad de medida** | Viajeros por mes (personas/mes). No son personas únicas, pernoctaciones, gasto turístico ni visitantes por departamento. |
| **Nivel de agregación** | Mensual. Total nacional y seis segmentos: Total, Vía Aérea, Vía Terrestre, Vía Marítima, América del Centro, América del Norte y Europa. |
| **Cobertura observada** | Enero 2009 – junio 2026 (210 meses). 2026 solo contiene enero–junio. |
| **Universo** | Registros de INGUAT/Migración procesados en los Laboratorios 1 y 2. Las vistas por país o frontera son descriptivas y no se publican como estimaciones modeladas. |

## Fuentes y columnas

**Tabla 2. Fuentes y columnas utilizadas**

| Elemento | Definición |
|---|---|
| **Fuente primaria** | Base_Migracion_2009-2026jun.xlsx (INGUAT/Migración), corte a junio 2026. El archivo no se incorpora a la imagen Docker; se monta como dato institucional. |
| **Columnas utilizadas** | Año, Mes cod, Vía, Frontera, País, Región dos, Tipo de Viajero y Viajero. |
| **Archivos derivados** | data/base_viajeros.csv.gz (detalle), data/series_mensuales.csv (serie observada), data/predicciones_lab1.csv y data/metricas_lab1.csv (resultados del Laboratorio 1). |
| **Construcción de la serie** | Suma de Viajero por Año y Mes cod. No se construye a partir de presencias diarias ni de una fuente distinta a la mensual. |
| **Filtro metodológico** | Se excluye Tipo de Viajero == "Viajero" en todas las series, excepto en Vía Marítima, que se usa completa. Esto responde al cambio de metodología 2022–2023 y evita duplicar visitantes. |
| **Faltantes y fechas** | Un mes sin fila en la fuente es un faltante, no un cero. Un cero solo es válido si la fuente lo reporta. Las fechas inválidas o los períodos esperados sin cobertura detienen el flujo. |

## Factor de reparto

El factor de reparto se documenta como el conjunto de proporciones con que la fuente distribuye el total de viajeros entre Turista, Excursionista, Viajero y Cruceristas. En la base recibida ese reparto ya está aplicado: por eso la columna Viajero contiene decimales y la suma por grupo recupera el total. El pipeline no vuelve a aplicar el factor, conserva los decimales hasta la

agregación y redondea solo para presentación. Si el equipo dispone de la tabla explícita de factores, se guarda en config/factores_reparto.csv y se versiona. Para la asignación a destinos se usa el factor oficial de la guía; en esta versión nacional cada llegada se cuenta una vez, por lo que el factor de asignación es 1.0.

## Períodos de ajuste, evaluación y publicación

**Tabla 3. Períodos del flujo**

| Etapa | Período | Uso |
|---|---|---|
| **Ajuste base** | 2009-01 a 2021-03 (147 meses) | Entrenamiento con el mismo corte del Laboratorio 1. |
| **Evaluación histórica** | 2021-04 a 2026-06 (63 meses) | Comparación con los resultados del Laboratorio 1. No es la única base de aceptación porque es un pronóstico multimensual y contiene la recuperación pospandemia. |
| **Backtest de aceptación** | 2025-07 a 2026-06 (12 cortes) | Evaluación principal con origen expansivo y un paso hacia adelante: en cada corte se ajusta solo con información anterior al mes evaluado. |
| **Pronóstico publicado** | 2026-07 a 2026-12 (6 meses) | Estimaciones hacia adelante con el corte de junio 2026. |
| **Sensibilidad ene–feb 2026** | Enero y febrero 2026 | Se pueden ocultar y estimar, pero se documenta la limitación: el corte actual ya contiene esos valores y el código se especificó después de verlos; además, la pandemia y el cambio metodológico impiden un contrafactual limpio. Si no hay observaciones comparables, no se calculan errores. |

## Parámetros y supuestos

**Tabla 4. Parámetros y supuestos del procedimiento**

| Parámetro o supuesto | Valor o criterio |
|---|---|
| **ARIMA por serie** | Total (1,0,1); Aérea (1,0,1); Terrestre (2,1,0); Marítima (2,0,3); Centro (1,0,0); Norte (3,0,0); Europa (4,1,2). |
| **Seasonal Naive** | Repite el mismo mes del año anterior. Se usa como referencia sencilla. |
| **Prophet** | Estacionalidad anual activa; semanal y diaria desactivadas. |
| **Transformación logarítmica** | Se aplica solo si la diferencia entre el CV anual máximo y mínimo es mayor que 0.25 y todos los valores son positivos. La regla queda en configuración y se registra por serie. |

| | |
|---|---|
| **Semilla y dependencias** | Semilla 20261029 para cualquier componente aleatorio. Versiones fijadas en requirements.txt o en el archivo de bloqueo y registradas en MLflow. |
| **Selección de modelo** | Los parámetros se fijan con el Laboratorio 1 y no se reajustan con el período de prueba. La regla de aceptación se define antes de ver los resultados y no se modifica después. |
| **Aditividad** | Las filas de la fuente son aditivas dentro de mes, vía, frontera, país, región y tipo de viajero. Si hay duplicados, se documenta si son registros parciales aditivos o un error; no se eliminan silenciosamente. |
| **Continuidad** | Las estimaciones suponen que el patrón histórico y la estacionalidad se mantienen. No anticipan pandemias, cambios metodológicos ni shocks externos. |
| **Revisiones de la fuente** | Si INGUAT revisa datos históricos, la versión publicada puede cambiar; por eso se registra el hash de la fuente y la fecha de generación. |
| **MAPE y redondeo** | El MAPE se calcula solo cuando las observaciones son mayores que cero. Si hay ceros, se reporta cuántas observaciones se excluyeron y se usan MAE/RMSE como métricas principales. Los valores se conservan con decimales en el archivo; el tablero redondea solo para mostrar. |

## Archivo de resultados que utilizará el tablero

La publicación se organiza en versiones inmutables y un puntero atómico. El tablero lee únicamente current.json y el archivo de la versión aprobada; nunca lee un archivo candidato. Si el puntero no existe o está corrupto, muestra “estimaciones no disponibles”.

**Tabla 5. Esquema mínimo de estimaciones.csv**

| Columna | Descripción |
|---|---|
| **destino** | Guatemala (o el destino asignado, si aplica). |
| **serie** | Total, Vía Aérea, Vía Terrestre, Vía Marítima, América del Centro, América del Norte o Europa. |
| **periodo** | Mes estimado, formato YYYY-MM-01. |
| **valor** | Viajeros por mes. |
| **unidad** | viajeros/mes. |
| **modelo** | Modelo que generó la estimación. |
| **conjunto** | evaluacion o pronostico. |
| **horizonte** | Meses hacia adelante; 0 en backtest. |
| **run_id** | Identificador de la ejecución en MLflow. |
| **fecha_generacion** | Fecha y hora ISO 8601. |
| **version_procedimiento** | Versión publicada, por ejemplo v2026.10.29-01. |

| | |
|---|---|
| **fuente_hash / config_hash** | SHA-256 de la fuente y de la configuración. |
| **estado** | aprobado o referencia. El tablero usa aprobado por defecto. |

metricas.csv incluye serie, modelo, periodo_inicio, periodo_fin, n_obs, MAE, RMSE, MAPE_pct, baseline, baseline_MAE, baseline_RMSE, cumple_regla y run_id. controles.csv incluye control, severidad, estado, n_afectados, detalle, run_id y timestamp. manifest.json conserva la versión, el run_id, el commit de Git, los hashes, los períodos, la fecha de aprobación y el resumen de métricas.

# Diagrama del flujo y puntos de control

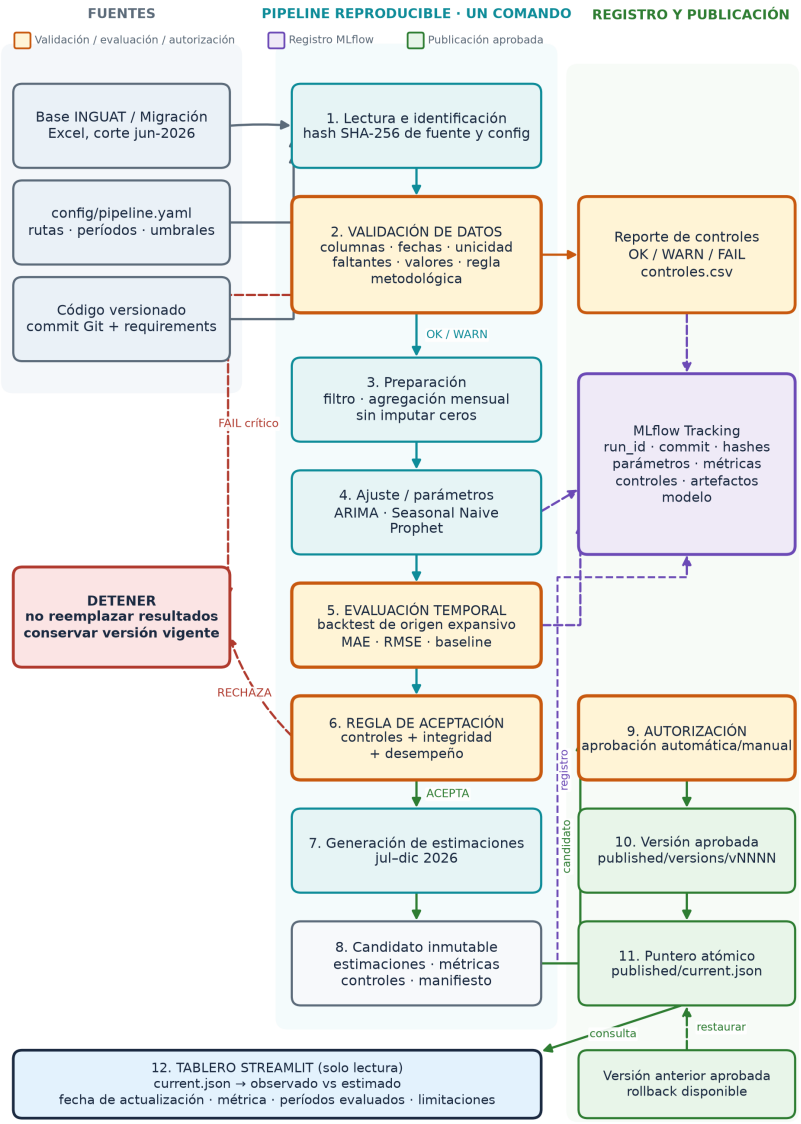



*Figura 1. Flujo MLOps del Observatorio de Turismo Sostenible. Elaboración propia.*

La validación ocurre antes de preparar las series: si falla un control crítico, el pipeline se detiene y no reemplaza los resultados vigentes. La evaluación se realiza después del ajuste y antes de generar la publicación; usa un backtest de origen expansivo para que cada estimación se calcule solo con información anterior al mes evaluado. La autorización ocurre después de registrar el candidato en MLflow; solo si se cumplen los controles y la regla de aceptación se actualiza el puntero de la versión aprobada.

**Tabla 6. Puntos de validación, evaluación y autorización**

| Punto de control | Etapa | Qué se decide | Evidencia |
|---|---|---|---|
| **Validación de datos** | Etapa 2 | Si los datos son aptos. Un FAIL crítico detiene el pipeline antes de preparar o reemplazar resultados. | Reporte de controles y artefacto en MLflow. |
| **Evaluación del procedimiento** | Etapa 5 | Si el modelo es aceptable. Se usan solo datos anteriores a cada corte; no hay fuga de información futura. | MAE, RMSE, MAPE y comparación con la referencia. |
| **Autorización de publicación** | Etapa 9 | Si el candidato reemplaza la versión vigente. Requiere controles críticos en OK, salidas válidas y cumplimiento de la regla de aceptación. | Run de MLflow y registro de aprobación. |
| **Publicación** | Etapas 10–11 | Se guarda una versión inmutable y se actualiza el puntero de forma atómica. Si falla, se conserva la versión anterior. | current.json y manifest.json. |
| **Consulta** | Etapa 12 | El tablero lee únicamente la versión aprobada y muestra fecha de actualización, métrica de validación, períodos evaluados y limitaciones. | Captura del tablero y versión consultada. |

La regla de aceptación queda parametrizada en config/pipeline.yaml. Su estructura es: (i) todos los controles críticos en OK; (ii) todas las estimaciones finitas, no negativas y dentro de un rango plausible; (iii) MAE/RMSE del candidato por debajo de umbrales absolutos según la escala de la serie y no peor que la referencia en más de un margen justificado; (iv) si no hay observaciones comparables, no se calculan errores ni se aprueba por desempeño. Los valores numéricos exactos se fijan en la sección 5 y se congelan antes de ejecutar.